```
import pandas as pd
import numpy as np

data = pd.read_csv("language.csv")
data
```

Out[4]:		Text	language
	0	klement gottwaldi surnukeha palsameeriti ning	Estonian
	1	sebes joseph pereira thomas på eng the jesuit	Swedish
	2	ถนนเจริญกรุง อักษรโรมัน thanon charoen krung เ	Thai
	3	விசாகப்பட்டினம் தமிழ்ச்சங்கத்தை இந்துப் பத்திர	Tamil
	4	de spons behoort tot het geslacht haliclona en	Dutch
	•••		•••
	21995	hors du terrain les années et sont des année	French
	21996	ใน พศ หลักจากที่เสด็จประพาสแหลมมลายู ชวา อินเ	Thai
	21997	con motivo de la celebración del septuagésimoq	Spanish
	21998	年月,當時還只有歲的她在美國出道,以mai-k名義推出首張英文《baby i like》,由	Chinese
	21999	aprilie sonda spațială messenger a nasa și-a	Romanian

22000 rows × 2 columns

```
In [5]: from sklearn.feature_extraction.text import CountVectorizer
In [6]: from sklearn.model_selection import train_test_split
In [7]: from sklearn.naive_bayes import MultinomialNB
In [8]: data
```

Out[8]:	Text	language			
0	klement gottwaldi surnukeha palsameeriti ning	Estonian			
1	sebes joseph pereira thomas på eng the jesuit	Swedish			
2	ถนนเจริญกรุง อักษรโรมัน thanon charoen krung เ	Thai			
3	விசாகப்பட்டினம் தமிழ்ச்சங்கத்தை இந்துப் பத்திர	Tamil			
4	de spons behoort tot het geslacht haliclona en	Dutch			
7	de spons benoon tot het gestacht haliciona en	Dutch			
•••		•••			
21995	hors du terrain les années et sont des année	French			
21996	ใน พศ หลักจากที่เสด็จประพาสแหลมมลายู ชวา อินเ	Thai			
21997	con motivo de la celebración del septuagésimoq	Spanish			
21998 年月,	當時還只有歲的她在美國出道,以mai-k名義推出首張英文《baby i like》,由	Chinese			
21999	aprilie sonda spațială messenger a nasa și-a	Romanian			
22000 rows × 2					
<pre>In [9]: data.isnull(</pre>).sum()				
Out[9]: Text language dtype: int64	0 0 1				
n [10]: data['langua	<pre>data['language'].value_counts()</pre>				
ut[10]: language Estonian Swedish English Russian Romanian Persian Pushto Spanish Hindi Korean Chinese French Portugese Indonesian Urdu Latin Turkish Japanese Dutch Tamil Thai Arabic Name: count,	1000 1000 1000 1000 1000 1000 1000 100				
data.dtypes	>				
[II]. data.utypes					

```
Out[11]: Text    object
    language    object

In [12]: X = np.array(data['Text'])
    y = np.array(data['language'])

In [13]: print(X)
```

['klement gottwaldi surnukeha palsameeriti ning paigutati mausoleumi surnukeha ol i aga liiga hilja ja oskamatult palsameeritud ning hakkas ilmutama lagunemise tun demärke aastal viidi ta surnukeha mausoleumist ära ja kremeeriti zlíni linn kand is aastatel – nime gottwaldov ukrainas harkivi oblastis kandis zmiivi linn aastat el – nime gotvald'

'sebes joseph pereira thomas på eng the jesuits and the sino-russian treaty of nerchinsk the diary of thomas pereira bibliotheca instituti historici s i -- rome libris '

'ถนนเจริญกรุง อักษรโรมัน thanon charoen krung เริ่มตั้งแต่ถนนสนามไชยถึงแม่น้ำเจ้าพระยาที่ถนนตก กรุงเทพมหานคร เป็นถนนรุ่นแรกที่ใช้เทคนิคการสร้างแบบตะวันตก ปัจจุบันผ่านพื้นที่เขตพระนคร เขตป้อมปรา บศัตรูพ่าย เขตสัมพันธวงศ์ เขตบางรัก เขตสาทร และเขตบางคอแหลม'

. . .

'con motivo de la celebración del septuagésimoquinto ° aniversario de la fundaci ón del departamento en guillermo ceballos espinosa presentó a la gobernación de caldas por encargo de su titular dilia estrada de gómez el himno que fue adoptado para solemnizar dicha efemérides y que siguieron interpretando las bandas de músi ca y los planteles de educación de esta sección del país en retretas y actos oficiales con gran aceptación[]\u200b'

'年月,當時還只有歲的她在美國出道,以mai-k名義推出首張英文《baby i like》,由美國的獨立廠牌bip·record發行,以外國輸入盤的形式在日本發售,旋即被抢购一空。其後於月日發行以倉木麻衣名義發行的首張日文單曲《love day after tomorrow》,正式於日本出道。這張單曲初動銷量只得約萬張,可是其後每週銷量一直上升,並於年月正式突破百萬銷量,合计万张。成為年最耀眼的新人歌手。'

' aprilie sonda spațială messenger a nasa și-a încheiat misiunea de studiu de a ni prăbușindu-se pe suprafața planetei mercur sonda a rămas fără combustibil fiin d împinsă de gravitația solară din ce în ce mai aproape de mercur']

```
In [14]: print(y)
    ['Estonian' 'Swedish' 'Thai' ... 'Spanish' 'Chinese' 'Romanian']
In [15]: cv = CountVectorizer()
    X = cv.fit_transform(X)

In [16]: X_train,X_test, y_train,y_test = train_test_split(X,y, test_size = 0.33,random_s
In [17]: X_train

Out[17]: <14740x277720 sparse matrix of type '<class 'numpy.int64'>'
    with 613529 stored elements in Compressed Sparse Row format>
In [18]: print(X_train)
```

```
(0, 197295)
                         2
           (0, 197708)
                         1
           (0, 197801)
                         1
           (0, 198388)
                         1
           (0, 197467)
                         1
           (0, 197865)
                         2
           (0, 197604)
                         1
           (0, 198428)
                         1
           (0, 198501)
                         1
           (0, 198556)
                         1
           (0, 197332)
                         1
           (0, 197485)
                          2
           (0, 198123)
                         1
          (0, 197892)
                         1
          (0, 197990)
                         1
           (0, 198053)
                         1
           (0, 198417)
                         1
          (0, 197623)
                         1
          (1, 197641)
                         2
           (1, 197314)
                         1
          (1, 197931)
                         1
           (1, 197804)
                         3
           (1, 198397)
                         1
           (1, 197149)
                         1
           (1, 197781)
           (14738, 188817)
                                  1
           (14738, 192004)
                                  1
                                  1
           (14738, 157171)
           (14738, 190346)
                                  1
           (14738, 190725)
                                  1
           (14738, 189685)
                                  1
                                  2
           (14738, 159269)
           (14738, 145431)
                                  1
           (14738, 173292)
                                  1
           (14738, 176062)
                                  1
           (14738, 159959)
                                  1
           (14738, 190198)
                                  1
           (14738, 167124)
                                  1
                                  1
           (14738, 168158)
           (14738, 180260)
                                  2
           (14738, 153262)
                                  1
                                  1
           (14738, 162150)
           (14738, 153355)
                                  1
           (14738, 178104)
                                  1
           (14738, 163770)
                                  1
                                  1
           (14739, 223002)
           (14739, 235170)
                                  1
           (14739, 222446)
                                  1
                                  1
           (14739, 221922)
          (14739, 242446)
                                  1
In [19]: print(y_test)
        ['Japanese' 'Russian' 'Latin' ... 'Turkish' 'Arabic' 'English']
          model = MultinomialNB()
In [21]: model.fit(X_train,y_train)
```